

实验目标

1. 理解判定树的基本概念（如熵、信息增益、Gini 指数、剪枝）
 2. 学习如何使用 scikit-learn 构建判定树
 3. 掌握数据预处理与特征选择
 4. 训练判定树分类器并评估模型性能
 5. 可视化判定树并解释结果
-

步骤指导

步骤 1：导入必要的库

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import accuracy_score, confusion_matrix,
classification_report
```

步骤 2：加载数据集

使用学生提供的数据集，如 water-melon.csv。

```
dataset = pd.read_csv("water-melon.csv") # 请更换为正确的文件名
```

显示前几行数据：

```
print(dataset.head())
```

步骤 3：数据探索

检查数据类型与缺失值：

```
print(dataset.info())  
print(dataset.isnull().sum()) # 确保没有缺失值
```

检查分类标签的分布：

```
sns.histplot(dataset['class'])  
plt.show()
```

步骤 4：特征工程

1. 将 class 设为目标变量 (y)
2. 删除 class 以获取特征 (X)
3. 对类别变量进行 One-Hot Encoding

```
X = dataset.drop(['class'], axis=1)  
y = dataset['class']
```

```
X = pd.get_dummies(X) # One-Hot Encoding 处理类别变量  
encoder = LabelEncoder()  
y = encoder.fit_transform(y)
```

检查处理后的数据：

```
print(X.head())  
print(y[:5])
```

步骤 5：划分训练集与测试集

```
X_train, X_test, y_train, y_test = train_test_split(X, y,  
test_size=0.2, random_state=1)
```

确认数据分割结果:

```
print(X_train.shape, X_test.shape)  
print(y_train.shape, y_test.shape)
```

步骤 6: 构建判定树模型

使用 Gini 指数:

```
clf_gini = DecisionTreeClassifier(criterion='gini', max_depth=3,  
random_state=0)  
clf_gini.fit(X_train, y_train)
```

```
plt.figure(figsize=(12,8))  
plot_tree(clf_gini, filled=True)  
plt.show()
```

使用 Entropy:

```
clf_entropy = DecisionTreeClassifier(criterion='entropy',  
max_depth=3, random_state=0)  
clf_entropy.fit(X_train, y_train)
```

```
plt.figure(figsize=(12,8))  
plot_tree(clf_entropy, filled=True)  
plt.show()
```

步骤 7: 模型预测与评估

对测试集进行预测:

```
y_pred_gini = clf_gini.predict(X_test)  
y_pred_entropy = clf_entropy.predict(X_test)
```

计算准确度:

```
print('Gini 准确度:', accuracy_score(y_test, y_pred_gini))
print('Entropy 准确度:', accuracy_score(y_test, y_pred_entropy))
```

查看混淆矩阵:

```
cm_gini = confusion_matrix(y_test, y_pred_gini)
cm_entropy = confusion_matrix(y_test, y_pred_entropy)
```

```
sns.heatmap(cm_gini, annot=True, fmt="d")
plt.title("Gini Confusion Matrix")
plt.show()
```

```
sns.heatmap(cm_entropy, annot=True, fmt="d")
plt.title("Entropy Confusion Matrix")
plt.show()
```

步骤 8: 结果分析与报告

```
print("Gini 判定树分类报告: \n", classification_report(y_test,
y_pred_gini))
print("Entropy 判定树分类报告: \n", classification_report(y_test,
y_pred_entropy))
```

鼓励学生回答:

1. Gini 和 Entropy 两种方法的结果是否一致?
 2. 是否出现过拟合问题?
 3. 判定树对数据的可解释性如何?
-

总结

- 本实验帮助学生 **理解并实作判定树**，从数据预处理到模型评估。
- 学生能够 **比较不同分裂标准（Gini vs. Entropy）**，评估结果并分析判定树的行为。

- 透过 **可视化判定树与混淆矩阵**，学生能够直观理解分类结果。

这样的实验步骤清晰，适合作为本科机器学习课程的实验内容！你可以根据学生的基础再调整难度。