

jumbokh /
ml-class2025

<> Code

Issues

Pull requests

Actions

Projects

Wiki

Security



main ▾

ml-class2025 / lab / 實驗二.md



jumbokh Create 實驗二.md

99caafd · 8 minutes ago



147 lines (115 loc) · 4.21 KB

Preview

Code

Blame



Raw



這是一個基於 **KNN (K-Nearest Neighbors)** 分類的實驗，適合用於機器學習入門課程。實驗內容將指導學生從數據預處理到模型評估，讓學生實際操作並理解 KNN 演算法的基本原理。

實驗：KNN (K-Nearest Neighbors) 分類

目標：

- 掌握 KNN 分類的基本概念與原理
- 了解如何使用 Python 與 `scikit-learn` 進行 KNN 分類
- 學習數據預處理與模型評估的方法

預備知識：

- Python 基礎
- NumPy、Pandas、Matplotlib、scikit-learn
- 基本機器學習概念（特徵、分類、模型評估）

步驟 1：導入必要的庫

首先，請確保已安裝 `numpy`、`pandas`、`matplotlib` 和 `scikit-learn`，然後導入這些庫：

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```



```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusio
```

步驟 2：加載並檢視數據

我們使用 `sklearn.datasets` 提供的 **Iris** 數據集，這是一個經典的分類數據集：

```
from sklearn.datasets import load_iris

# 加載數據集
iris = load_iris()
X = iris.data # 特徵
y = iris.target # 標籤 (0, 1, 2 對應不同類別)

# 轉換為 DataFrame 方便觀察
df = pd.DataFrame(X, columns=iris.feature_names)
df['target'] = y
print(df.head())
```



問題 1：請觀察數據集的特徵，哪些特徵可能對分類有較大影響？

步驟 3：數據預處理

(1) 拆分訓練集與測試集

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, ra
```



此步驟將數據集分為 **80% 訓練集** 和 **20% 測試集**。

(2) 特徵標準化

KNN 受數值範圍影響，因此需要標準化：

```
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```



步驟 4：訓練 KNN 模型

```
# 設置 K 值 (默認為 3)
k = 3
knn = KNeighborsClassifier(n_neighbors=k)

# 訓練模型
knn.fit(X_train, y_train)

# 進行預測
y_pred = knn.predict(X_test)
```



步驟 5：模型評估

(1) 計算準確率

```
accuracy = accuracy_score(y_test, y_pred)
print(f"模型準確率: {accuracy:.2f}")
```



(2) 顯示分類報告

```
print("分類報告:")
print(classification_report(y_test, y_pred, target_names=iris.target_names))
```



(3) 混淆矩陣

```
import seaborn as sns

cm = confusion_matrix(y_test, y_pred)
plt.figure(figsize=(5, 4))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', xticklabels=iris.target_
plt.xlabel('預測標籤')
plt.ylabel('真實標籤')
plt.title('混淆矩陣')
plt.show()
```



問題 2：從混淆矩陣中，你能看出哪些類別最容易被誤分類嗎？

步驟 6：選擇最佳的 K 值

不同的 K 值會影響分類效果，我們可以測試不同的 K 值來選擇最佳參數：

```
k_values = range(1, 21)
accuracies = []

for k in k_values:
    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(X_train, y_train)
    y_pred = knn.predict(X_test)
    accuracies.append(accuracy_score(y_test, y_pred))

# 繪製 K 值與準確率的關係圖
plt.figure(figsize=(8, 5))
plt.plot(k_values, accuracies, marker='o', linestyle='dashed')
plt.xlabel("K 值")
plt.ylabel("準確率")
plt.title("不同 K 值的準確率變化")
plt.show()
```



問題 3：根據圖表，選擇一個較佳的 K 值，並解釋你的選擇。

實驗總結

請回答以下問題來反思這次實驗：

1. KNN 分類的原理是什麼？為何 K 值的選擇會影響結果？
2. 這個模型在哪些應用場景中可能表現較好？哪些情境下可能不適合？
3. 如果數據集的特徵維度更高，KNN 是否仍然是一個好的選擇？為什麼？

這份實驗導引能夠讓學生從數據預處理、模型訓練到評估與超參數選擇，完整掌握 KNN 分類的核心概念與應用。如果有進一步的需求，例如增加噪聲數據來測試 KNN 的穩健性，也可以擴展這份內容。