

ThinkSystem ST45 V3

AMD 直立式伺服器 搭配實體 Raid Card



早鳥優惠價
NT\$39,900
(含稅)

Lenovo

程式人 | 林信良

從疾病檢驗到單純貝氏分類

在各種分類方法當中，面對基於貝氏定理的單純貝氏分類，我們可以從生活實例理解，像是疾病檢驗、垃圾郵件、氣象，進一步地抽取現象的特徵作為計算

文/ 林信良 | 2021-08-12 發表



單純貝氏分類 (Naive bayes classifier) 是基於貝氏定理，那麼，貝氏定理又是什麼呢？若不小心迷失在 $P(A|B)$ 、 $P(A)$ 等公式的符號中，不妨從生活實例開始理解，進一步地抽取現象的特徵作為計算，就可以應用單純貝氏分類。

貝氏定理與疾病檢驗

在機器學習的領域中，單純貝氏分類是諸多分類方法中的一個，它從貝氏定理

$P(A|B)=P(B|A)*P(A)/P(B)$ 出發，其中 $P(A)$ 、 $P(B)$ 各代表 A、B 事件發生的機率， $P(A|B)$ 代表在觀察到 B 事件時，又觀察到 A 事件的機率， $P(B|A)$ 代表在觀察到 A 事件時，又觀察到 B 事件的機率。

對許多人來說，機率本身就是個難以捉摸的概念，用符號來認識貝氏定理，就更難以想像其意義了。我們可以從另一個角度來認識，抽菸且得肺癌的機率可以寫為 $P(\text{肺癌}|\text{抽菸})$ ，得肺癌而且有抽菸的機率可以寫為 $P(\text{抽菸}|\text{肺癌})$ ，貝氏定理告訴我們， $P(\text{肺癌}|\text{抽菸})$ 與 $P(\text{抽菸}|\text{肺癌})$ 有正相關，從直覺上來想也是如此，抽菸容易得肺癌，相對地也表示，得肺癌的人很可能有抽菸。

但是，過多的直覺有時不代表事實，例如，若有個試劑可以檢驗某個疾病，試劑會有真陽（得病者被驗為陽性）、真陰（未得病者被驗為陰性）、偽陽（未得病者被驗為陽性）、偽陰（得病者被驗為陰性），若某檢驗後各自人數分別記為 TP、TN、FP、FN，我們可以使用召回率（Recall）作為評估試劑的指標之一，計算方式為 $TP/(TP+FN)$ 。

這裡所謂的召回率，簡單來說，就是得病且被試劑驗出陽性的機率，可以記為 $P(\text{陽性}|\text{得病})$ ，單純依賴直覺的話，若 $P(\text{陽性}|\text{得病})$ 很高，例如高達百分之 99，想必 $P(\text{得病}|\text{陽性})$ 也很高吧！也就是檢驗出陽性的人，十之八九就一定有病嗎？畢竟根據貝氏定理，「 $P(\text{得病}|\text{陽性})=P(\text{陽性}|\text{得病})*P(\text{得病})/P(\text{陽性})$ 」嘛！

$P(\text{陽性}|\text{得病})$ 與 $P(\text{得病}|\text{陽性})$ 確實是有正相關，不過別忘了 $P(\text{得病})$ 與 $P(\text{陽性})$ ， $P(\text{得病})$ 是總人口中得到該病的機率，可以從既有的資料中計算，假設計算後是百分之 0.1， $P(\text{陽性})$ 是被試劑檢驗為陽性的機率，也就是真陽性機率與真陰性機率的和，若計算後得到為 0.022，依貝氏定理， $P(\text{得病}|\text{陽性})=0.99*0.001/0.022=0.045$ 。

雖然，得病被試劑驗出陽性的機率高達百分之 99，然而，在試劑檢驗為陽性的情況下，該人真正得病的機率卻只有百分之 4.5，這還滿違反許多人的直覺，原因在於 $P(\text{得病})$ 只有百分之 0.2， $P(\text{得病})$ 就是俗稱的疫病盛行率，也就是說，在疫病盛行率不高的情況下，透過試劑檢驗來抓出真正的得病者在機率上並不高。

簡單的垃圾郵件分類

那麼，貝氏定理又跟機器學習有什麼關係了？

$P(A|B)=P(B|A)*P(A)/P(B)$ 這個公式，等號右邊其實代表著事前已經得知的各種機率，就像上述的例子，陽性、得病等各種機率，我們可以從既有的資料中計算；而貝氏定理等號的左邊，可以代表針對新資料預測的機率，例如在試劑檢驗為陽性的情況下，真正有得病的機率，也就是說，可以從既有資料中生成機率模型，從而預測某條件機率，

現在來換個例子，如果你的信箱從不篩選垃圾郵件，從收過的郵件中選出一封，郵件中包含「優惠」字眼的機率是 $P(\text{優惠})$ ，而任選出的郵件是垃圾郵件的機率若是 $P(\text{垃圾})$ ，是垃圾郵件且包含「優惠」字眼的條件機率是 $P(\text{優惠}|\text{垃圾})$ ，現在若收到了一封新郵件，其中包含了「優惠」字眼，那麼，它是垃圾郵件的機率有多高呢？

當我們已經知道貝氏定理，此時，就可以用「 $P(\text{優惠}|\text{垃圾})*P(\text{垃圾})/P(\text{優惠})$ 」來計算，在進一步以實際數字說明前，我們可以再認識一個公式 $P(B)=P(B|A)*P(A)+P(B|\text{not-}A)*P(\text{not-}A)$ ，其中 $\text{not-}A$ 表示未發生 A 事件，如果 A 事件發生的機率是0.5，那麼 $P(A)$ 就等於 $P(\text{not-}A)$ 。

這時，貝氏定理 $P(A|B)=P(B|A)*P(A)/P(B)$ 的等號右邊，就可以寫為 $P(B|A)*P(A)/(P(B|A)*P(A)+P(B|\text{not-}A)*P(\text{not-}A))$ ，將相同的 $P(A)$ 、 $P(\text{not-}A)$ 抵消，最後就得到 $P(B|A)/(P(B|A)+P(B|\text{not-}A))$ 。

也就是說，在假設任選出的郵件為機率是0.5的情況下，若 $P(\text{優惠}|\text{垃圾})$ 是0.6， $P(\text{優惠}|\text{not-垃圾})$ 是0.1，那麼，包含了「優惠」字眼又是垃圾郵件的機率，就可以用「 $P(\text{優惠}|\text{垃圾})/(P(\text{優惠}|\text{垃圾})+P(\text{優惠}|\text{not-垃圾}))$ 」來計算，也就是 $0.6/(0.6+0.1)=0.85$ ，看來包含「優惠」字眼的話，滿有可能是垃圾郵件！

單純貝氏分類

當然，一封信件裡，實際上，可作為識別垃圾郵件的字眼不會只有一個，常用且簡單的文件特徵抽取方式之一是詞袋 (bag-of-words) 模型，例如，若字眼清單為「優惠、降價、限時、打折、好禮、領取、免費、好康」，對於一封郵件，基本的特徵向量可以用有或沒有出現字眼來表示，例如，特徵向量 $[1,0,1,1,0,1,0,0]$ 表示信中同時出現了「優惠、限時、打折、領取」字眼。

若以 x_i 表示特徵向量的第 i 個分量，信中同時出現「優惠、限時、打折、領取」字眼的機率，可以表示為 $P(x_1=1, x_2=0, x_3=1, \dots, x_8=0 | \text{垃圾})$ 。為了單純化，假設字眼清單中每個字眼的出現都是獨立事件，也就是出現某字眼與否，與其他字眼出現與否無關，對於獨立事件， $P(x_1=1, x_2=0, x_3=1, \dots, x_8=0 | \text{垃圾})$ 等於 $P(x_1=1 | \text{垃圾}) * P(x_2=0 | \text{垃圾}) * \dots * P(x_8=0 | \text{垃圾})$ 。

也就是說，若 $X=[1,0,1,1,0,1,0,0]$ ，「 $P(X | \text{垃圾}) / (P(X | \text{垃圾}) + P(X | \text{not-垃圾}))$ 」就表示同時出現「優惠、限時、打折、領取」字眼的情況下，是垃圾郵件的機率，若假設字眼的出現是獨立事件，其中 $P(X | \text{垃圾})$ 、 $P(X | \text{not-垃圾})$ 的部份，都可以用垃圾郵件中個別字眼出現機率，以相乘的方式來計算，再根據得到的機率判定是不是垃圾郵件，這就是單純貝氏分類的基本原理。

實際上，字眼出現與否，彼此間還是會有些關聯，然而，單純貝氏分類假設它們是獨立事件，這就是其單純、天真之處，就方才談到的基本原理來說，單純貝氏分類實作簡單且執行快速，雖然有獨立事件的非現實假設，但是，單純貝氏分類通常還是有不錯的表現，特別是對於資料量不大的情況，這邊使用垃圾郵件判定為例，正是因為現實中也會使用單純貝氏分類，來作為垃圾郵件篩選器。

方才例子，字眼的特徵不是連續的，且未討論個別特徵分布的狀況，針對不同特徵與分布，有多項式單純貝氏、高斯單純貝氏、白努利單純貝氏等方法，像 `sklearn` 程式庫，就分別提供 `MultinomialNB`、`GaussianNB`、`BernoulliNB` 等實作，例如，人的身高、體重等具有高斯分布的連續型資料，或許可以採用高斯單純貝氏來處理分類的任務。

試著從生活實例中理解

在面對機率方面的問題或方法時，單看公式經常不易理解，其實生活中就有許多實例可循。例如，下雨通常伴隨著黑雲，這是屬於條件機率，只不過生活實例有時過於依賴直覺而不精確罷了，例如，如果看到黑雲，下雨的機會就高嗎？

這時可試想，這地區或季節下雨的機會是多少？出現黑雲的機會又是多少？試著多想幾個這類例子，就不難理解貝氏定理，而這些理解過程可以進一步擴展，將一些現象的特徵抽取出來作為計算基礎，就可以應用單純貝氏分類來做點分析了。

專欄作者



林信良

因在網路上經營「良葛格學習筆記」(openhme.cc)而聞名，曾任昇陽教育訓練中心技術顧問、甲骨文教育訓練中心授權講師，目前為自由工作者，專長為技術寫作、翻譯與教育訓練。喜好研究程式語言、框架、社群，從中學習設計、典範及文化。閒暇之餘記錄所學，技術文件涵蓋C/C++、Java、Ruby/Rails、Python、JavaScript、Haskell等多個領域。

CYBERSEC 2025 臺灣資安大會 | 4/15-4/17 臺北南港展覽二館

Security Strategy & Case Study

當防禦機制毫無異常，攻擊是否已悄然展開？

🕒 4A 🕒 4/16 14:00 - 14:30

Nico Chen NEITHNET 防駭架構部 專案經理


海洋研究機構資安治理初探與未來展望

🕒 4A 🕒 4/16 15:30 - 16:00

許友貞 財團法人國家實驗研究院台灣海洋科技研究中心 資訊資安組 正工程師兼組長

📺 iT+ 直播研討會


熱門新聞




微軟為誤刪兩款受歡迎的VS Code擴充程式道歉
2025-03-17



中國駭客UNC3886對Juniper路由器設備下手，植入後門程式TinyShell變種
2025-03-14



Gemini聊天機器人將在今年全面取代Google Assistant
2025-03-17



Google Gemini Flash Thinking模型升級、強化Deep Research、整合Google App
2025-03-17