
皮馬印第安人糖尿病分類案例研究報告

1. 案例背景與研究目的

本研究基於皮馬印第安人（也被稱為河流民族）的糖尿病案例數據集。皮馬印第安人是一個原本以農業為基礎、飲食富含纖維和維生素的社群。然而，由於美國政府建造的灌溉系統改變了他們的環境，導致了長達 40 年的饑荒，嚴重影響了他們的傳統飲食和運動習慣。糖尿病的發生與飲食、運動和基因有著密切關係。這個資料集提供了一個機會，讓我們能夠研究歷史上的因果關係，並以數值數據來佐證皮馬印第安女性受到糖尿病影響的情況。

本研究的主要目的是分類或預測患者是否容易患有糖尿病，基於多個特徵。這是一個二元分類問題，資料集包含了多個數值型特徵。

2. 資料集描述

資料集包含 768 個案例和 9 個欄位（特徵）。這些特徵包括：

- Pregnancies (懷孕次數)
- Glucose (口服葡萄糖耐受測試中 2 小時後的血漿葡萄糖濃度)
- BloodPressure (舒張壓，毫米汞柱)
- SkinThickness (三頭肌皮膚褶層厚度，毫米)
- Insulin (2 小時血清胰島素， $\mu\text{U/ml}$)
- BMI (身體質量指數，體重 $\text{kg} / (\text{身高 m})^2$)
- DiabetesPedigreeFunction (糖尿病譜系函數)
- Age (年齡，歲)
- Outcome (類別變數，0 或 1)

資料集中共有 768 筆記錄，所有欄位都沒有缺失值。Outcome 欄位顯示，有 268 個案例 Outcome 為 1（糖尿病），其餘為 0（非糖尿病）。這意味著資料集是非平衡的，非糖尿病案例與糖尿病案例的比例約為 2:1。

透過研究這個資料集和相關筆記本，您將能夠學習到：

- 資料視覺化
- 資料縮放
- 用於特徵選擇的統計測試
- 演算法的建模與結果視覺化
- 模型在平衡和不平衡資料集上訓練時性能的差異
- 分類器的堆疊 (Stacking)

3. 探索性資料分析 (EDA)

EDA 部分旨在理解資料的特性和分佈。

- **特徵分佈:** Pregnancies、Insulin、DiabetesPedigreeFunction 和 Age 特徵顯示出**右偏分佈**。BloodPressure 和 Skin Thickness 顯示出**雙峰分佈**。Glucose 和 BMI 的分佈接近常態或雙峰分佈，這可能是由於存在數值為 0 的情況。Outcome 特徵顯示了非平衡的 2:1 比例，這種不平衡會導致預測**偏向非糖尿病案例**，並使得視覺化難以獲得準確的洞察。
- **平均值比較:** 比較糖尿病組和非糖尿病組特徵的平均值顯示：
 - 懷孕平均次數 (Pregnancies): 糖尿病組 (4.87) 高於非糖尿病組 (3.30)。
 - 葡萄糖平均值 (Glucose): 糖尿病組 (141.26) 顯著高於非糖尿病組 (109.98)，是預測糖尿病的良好指標。
 - 血壓平均值 (BloodPressure) 和皮膚厚度平均值 (SkinThickness): 兩組之間沒有顯著差異。
 - 胰島素平均值 (Insulin): 糖尿病組 (100.34) 高於非糖尿病組 (68.79)。
 - BMI 平均值: 糖尿病組 (35.14) 高於非糖尿病組 (30.30)。
 - 糖尿病譜系函數平均值 (DiabetesPedigreeFunction): 糖尿病組 (0.55) 略高於非糖尿病組 (0.43)。
 - 年齡平均值 (Age): 糖尿病組 (37.07) 高於非糖尿病組 (31.19)。
- **特徵與結果的關係視覺化:** 為了更好地視覺化具有大量獨特數值的特徵與結果的關係，部分特徵 (Glucose, Insulin, BMI, DiabetesPedigreeFunction) 被轉換為分組 (例如，將數值除以一個常數) 進行視覺化。視覺化結果顯示了一些潛在的趨勢，例如血糖值高於 125 與糖尿病的可能性非常高相關。

4. 領域知識 (Domain Information)

來源提供了一些關於各特徵與糖尿病之間關係的領域知識，這些知識來自網站和研究論文。例如，妊娠糖尿病、高血糖與糖尿病的關係、高血壓可能導致第二型糖尿病、BMI 與肥胖導致第二型糖尿病的關係、糖尿病譜系函數反映家族史的影響等。來源提到，從 EDA 獲得的數值範圍與領域知識存在一些不匹配。這強調了需要進行進一步的特徵工程和分析。

5. 特徵工程 (Feature Engineering)

特徵工程是為了改善資料質量並使其更適合機器學習模型的重要步驟。

- **資料縮放 (Data Scaling):** 機器學習模型無法理解特徵值的單位，因此需要縮放數據。來源提到了兩種縮放選項：**正規化 (Normalization)** 和**標準化 (Standardization)**。根據來源的解釋，對於非常態分佈的特徵 (如右偏)，應進行正規化；對於數值很大或很小但呈常態分佈的特徵，應進行標準化。來源提到 Pregnancies, Insulin, DiabetesPedigreeFunction 和 Age 由於顯示右偏分佈而被正規化。然而，提供的程式碼顯示 Pregnancies 使用了 MinMaxScaler (Normalization)，而 Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction, Age 都使用了 StandardScaler (Standardization)。這一步的目的是確保模型不受特徵幅度差異的影響。
- **相關性分析 (Correlation Analysis):** 相關性分析顯示 SkinThickness 和 BloodPressure 與 Outcome 沒有顯著相關性。Glucose 顯示出最高的正相關性，其次是 BMI, Age, Pregnancies, DiabetesPedigreeFunction 和 Insulin。
- **特徵選擇 (Feature Selection):** 使用 **ANOVA 測試 (f_classif)** 這種統計方法來評估數值型特徵的重要性。ANOVA 分數越高，特徵越重要。根據 ANOVA 測試結果，需要**捨棄 (drop)** SkinThickness 和 BloodPressure 這兩個特徵，剩餘的特徵被用於建模。

6. 資料平衡 (Data Balancing)

如前所述，資料集存在類別不平衡的問題。為了解決這個問題，來源採用了資料平衡技術。

- 來源提到了處理不平衡資料的兩種選項：欠取樣 (Undersampling) 和過取樣 (Oversampling)。
- 在這個案例中，選擇了過取樣少數類別的方法，具體使用了 **SMOTE (Synthetic Minority Over-sampling Technique)** 技術。SMOTE 通過合成新的少數類別樣本來增加其數量，使其與多數類別數量相同。經過 SMOTE 處理後，糖尿病和非糖尿病案例的數量都變成了 500 個。
- 來源強烈建議，由於 SMOTE 生成了合成數據，在評估模型時不要使用準確度 (accuracy)，因為這會產生誤導。應使用混淆矩陣 (confusion matrix) 和 ROC-AUC 圖表/分數來進行模型評估。

7. 建模與結果比較

將經過特徵選擇後的數據（包括非平衡和經 SMOTE 平衡的數據）分割成 75% 的訓練集和 25% 的測試集。然後使用幾種分類器進行建模：

- XGBoost 分類器 (XGBClassifier)
- LightGBM 分類器 (LGBMClassifier)
- XGBoost 和 LightGBM 的堆疊分類器 (StackingClassifier)

模型性能使用交叉驗證分數 (Cross Validation Score) 和 ROC-AUC 分數進行評估。同時使用混淆矩陣和分類報告進行詳細評估。

以下是模型在非平衡和平衡資料集上的性能比較：

模型	資料集	交叉驗證分數 (ROC AUC)	ROC AUC 分數 (測試集)
XGBClassifier	非平衡	83.60%	67.16%
XGBClassifier	平衡	86.71%	78.60%
LightGBMClassifier	非平衡	82.36%	64.20%
LightGBMClassifier	平衡	86.21%	77.43%
Stack (XGBClassifier + LGBMClassifier)	非平衡	80.15%	65.70%
Stack (XGBClassifier + LGBMClassifier)	平衡	84.35%	75.88%

8. 結論

這是一個能讓我們深入研究皮馬印第安人糖尿病特殊案例的優秀資料集。透過 EDA 和領域知識的結合，我們獲得了一些關於哪些特徵與糖尿病相關的見解。

SMOTE 分析被用於資料平衡。為了凸顯模型在非平衡和平衡資料上訓練時的性能差異，使用了基於樹的模型（XGBoost 和 LightGBM）進行訓練。

結果顯示，LightGBM 和 XGBoost 的性能非常接近。儘管嘗試了堆疊這兩種分類器，但堆疊模型並未超越單獨的模型。**總體而言，當模型在平衡資料集上訓練時，觀察到明顯的性能改進。**這證實了處理資料不平衡對於提高模型性能的重要性。
