

除去变量 Q_i 外的其他变量.

输入: 贝叶斯网 $B = \langle G, \Theta \rangle$;
 采样次数 T ;
 证据变量 $\mathbf{E}$ 及其取值 $\mathbf{e}$;
 待查询变量 $\mathbf{Q}$ 及其取值 $\mathbf{q}$.

过程:

- 1: $n_q = 0$
- 2: $\mathbf{q}^0$ = 对 $\mathbf{Q}$ 随机赋初值
- 3: for $t = 1, 2, \dots, T$ do
- 4: for $Q_i \in \mathbf{Q}$ do
- 5: $\mathbf{Z} = \mathbf{E} \cup \mathbf{Q} \setminus \{Q_i\}$;
- 6: $\mathbf{z} = \mathbf{e} \cup \mathbf{q}^{t-1} \setminus \{q_i^{t-1}\}$;
- 7: 根据 B 计算分布 $P_B(Q_i | \mathbf{Z} = \mathbf{z})$;
- 8: q_i^t = 根据 $P_B(Q_i | \mathbf{Z} = \mathbf{z})$ 采样所获 Q_i 取值;
- 9: $\mathbf{q}^t$ = 将 $\mathbf{q}^{t-1}$ 中的 q_i^{t-1} 用 q_i^t 替换
- 10: end for
- 11: if $\mathbf{q}^t = \mathbf{q}$ then
- 12: $n_q = n_q + 1$
- 13: end if
- 14: end for

输出: $P(\mathbf{Q} = \mathbf{q} | \mathbf{E} = \mathbf{e}) \simeq \frac{n_q}{T}$

图 7.5 吉布斯采样算法

需注意的是, 由于马尔可夫链通常需很长时间才能趋于平稳分布, 因此吉布斯采样算法的收敛速度较慢. 此外, 若贝叶斯网中存在极端概率“0”或“1”, 则不能保证马尔可夫链存在平稳分布, 此时吉布斯采样会给出错误的估计结果.

7.6 EM算法

在前面的讨论中, 我们一直假设训练样本所有属性变量的值都已被观测到, 即训练样本是“完整”的. 但在现实应用中往往会遇到“不完整”的训练样本, 例如由于西瓜的根蒂已脱落, 无法看出是“蜷缩”还是“硬挺”, 则训练样本的“根蒂”属性变量值未知. 在这种存在“未观测”变量的情形下, 是否仍能对模型参数进行估计呢?

未观测变量的学名是“隐变量”(latent variable). 令 $\mathbf{X}$ 表示已观测变量集, $\mathbf{Z}$ 表示隐变量集, Θ 表示模型参数. 若欲对 Θ 做极大似然估计, 则应最大化对数似然

$$LL(\Theta | \mathbf{X}, \mathbf{Z}) = \ln P(\mathbf{X}, \mathbf{Z} | \Theta). \quad (7.34)$$

然而由于 $\mathbf{Z}$ 是隐变量, 上式无法直接求解. 此时我们可通过对 $\mathbf{Z}$ 计算期望, 来

由于“似然”常基于指数族函数来定义, 因此对数似然及后续 EM 迭代过程中一般是使用自然对数 $\ln(\cdot)$.

最大化已观测数据的对数“边际似然”(marginal likelihood)

$$LL(\Theta | \mathbf{X}) = \ln P(\mathbf{X} | \Theta) = \ln \sum_{\mathbf{Z}} P(\mathbf{X}, \mathbf{Z} | \Theta). \quad (7.35)$$

直译为“期望最大化算法”，通常直接称EM算法。

这里仅给出EM算法的一般描述，具体例子参见9.4.3节。

EM (Expectation-Maximization) 算法 [Dempster et al., 1977] 是常用的估计参数隐变量的利器，它是一种迭代式的方法，其基本想法是：若参数 Θ 已知，则可根据训练数据推断出最优隐变量 $\mathbf{Z}$ 的值 (E 步)；反之，若 $\mathbf{Z}$ 的值已知，则可方便地对参数 Θ 做极大似然估计 (M 步)。

于是，以初始值 Θ^0 为起点，对式(7.35)，可迭代执行以下步骤直至收敛：

- 基于 Θ^t 推断隐变量 $\mathbf{Z}$ 的期望，记为 $\mathbf{Z}^t$ ；
- 基于已观测变量 $\mathbf{X}$ 和 $\mathbf{Z}^t$ 对参数 Θ 做极大似然估计，记为 Θ^{t+1} ；

这就是 EM 算法的原型。

进一步，若我们不是取 $\mathbf{Z}$ 的期望，而是基于 Θ^t 计算隐变量 $\mathbf{Z}$ 的概率分布 $P(\mathbf{Z} | \mathbf{X}, \Theta^t)$ ，则 EM 算法的两个步骤是：

- E 步 (Expectation)：以当前参数 Θ^t 推断隐变量分布 $P(\mathbf{Z} | \mathbf{X}, \Theta^t)$ ，并计算对数似然 $LL(\Theta | \mathbf{X}, \mathbf{Z})$ 关于 $\mathbf{Z}$ 的期望

$$Q(\Theta | \Theta^t) = \mathbb{E}_{\mathbf{Z} | \mathbf{X}, \Theta^t} LL(\Theta | \mathbf{X}, \mathbf{Z}). \quad (7.36)$$

- M 步 (Maximization)：寻找参数最大化期望似然，即

$$\Theta^{t+1} = \arg \max_{\Theta} Q(\Theta | \Theta^t). \quad (7.37)$$

简要说来，EM 算法使用两个步骤交替计算：第一步是期望(E)步，利用当前估计的参数值来计算对数似然的期望值；第二步是最大化(M)步，寻找能使 E 步产生的似然期望最大化的参数值。然后，新得到的参数值重新被用于 E 步，……直至收敛到局部最优解。

EM 算法的收敛性分析参见 [Wu, 1983]。

EM 算法可看作坐标下降 (coordinate descent) 法来最大化对数似然下界的过程。坐标下降法参见附录 B.5。

事实上，隐变量估计问题也可通过梯度下降等优化算法求解，但由于求和的项数将随着隐变量的数目以指数级上升，会给梯度计算带来麻烦；而 EM 算法则可看作一种非梯度优化方法。