

主成分分析：数据降维与可视化的强大工具

主成分分析（PCA）是应用最广泛的无监督算法之一，它是一种基础但强大的降维工具，特别适用于数据可视化、噪音过滤、特征抽取和特征工程等领域。

PCA的核心思想是在数据中找到一组主轴，并用这些主轴来描述数据集。这些主轴表示数据的主要方差方向，通过它们可以将高维数据投影到低维空间，同时保留数据的主要信息。

在本演示中，我们将探索PCA的基本概念、降维应用、数据可视化技术、噪音过滤能力以及在人脸识别等实际场景中的应用。



投稿人：**Kunta Hsieh**



主成分分析的基本原理

主成分分析的核心是寻找数据中的主轴，这些轴代表数据变化的主要方向。在二维数据示例中，我们可以清晰看到PCA如何工作：它找出数据分布的主要方向，并用这些方向作为新的坐标轴。


PCA通过计算"成分"和"可解释差异"来量化数据关系。成分定义了主轴的方向，而可解释差异则表示沿该方向的数据方差大小。箭头的长度表示各个轴的"重要程度"，衡量了数据投影到主轴上的方差大小。

这种从原始坐标轴到主轴的变换是一个仿射变换，包含平移、旋转和均匀缩放三个步骤。通过这种变换，我们可以用更少的维度表达数据的主要特征。

PCA的数学表示

PCA找到的主轴是数据协方差矩阵的特征向量，而可解释差异则是对应的特征值。这些特征向量按特征值大小排序，形成了数据的主成分。

在Scikit-Learn中，我们可以通过PCA评估器轻松实现这一过程，获取成分和可解释差异等关键指标。






用PCA进行降维

PCA降维意味着去除一个或多个最小主成分，从而得到一个更低维度但保留最大数据方差的数据投影。这种方法在处理高维数据时特别有价值。

在降维过程中，沿着最不重要的主轴的信息被去除，仅留下含有最高方差值的数据成分。被去除的那一小部分方差值基本可以看成是数据在降维后损失的"信息"量。

即使在降维后，数据的总体关系仍然被大致保留下来。这就是PCA的强大之处：它能够在大幅减少数据维度的同时，保留数据中最重要的信息。




PCA用于数据可视化：手写数字案例

当数据维度很高时，PCA的降维价值更加明显。以手写数字数据为例，每个图像是 8×8 像素，即64维数据。通过PCA，我们可以将这些数据投影到二维平面，直观地观察数据点之间的关系。

在这个案例中，我们将64维的手写数字数据投影到二维空间。虽然二维投影会损失很多信息，但它让我们能够直观地看到不同数字之间的分布关系。从累计方差贡献率图可以看出，需要约20个成分才能保持90%的方差。

PCA的这种可视化能力使我们能够理解高维数据中的模式和结构，这在数据探索阶段非常有价值。




PCA成分的含义

PCA成分的含义可以从基向量的组合角度来理解。在手写数字数据中，每幅图像都是由64个像素值定义的。传统方法是用每个像素作为基向量，但这种表示方法并不是最优的。

PCA提供了一种更有效的表示方法：它找到一组最优基函数，使得这些基函数中前几个加起来就足以重构数据集中的大部分元素。这些基函数是数据本身的特性，而不是预先定义的。

与逐像素表示相比，PCA基可以通过为一个均值加上少量成分，来恢复输入图像最显著的特征。这就是PCA提供数据低维表示的原理：它发现一组比原始像素基向量更能有效表示输入数据的基函数。



像素基表示

使用每个像素作为基向量

- 直观但不高效
- 需要所有像素才能完整表示图像
- 丢弃部分像素会导致信息严重损失

PCA基表示

使用主成分作为基向量

- 更高效的表示方法
- 少量成分可以捕捉大部分信息
- 基于数据本身的特性

成分选择

根据累计方差贡献率选择成分数量

- 权衡信息保留与维度减少
- 通常选择保留90%方差的成分数
- 可视化累计方差曲线辅助决策

用PCA进行噪音过滤

PCA也可以被用作噪音数据的过滤方法。由于主成分的方差远大于噪音的方差，所以主成分相对不受噪音影响。通过仅用主成分的最大子集重构数据，我们可以选择性地保留信号并丢弃噪音。

在手写数字数据的案例中，我们首先向原始数据添加随机噪音，然后用PCA进行降维和重构。通过保留50%的方差（对应12个主成分），我们可以有效地过滤掉大部分噪音，恢复出相对清晰的数字图像。

这种信号保留/噪音过滤的特性使PCA成为一种非常有用的特征选择方式。在实际应用中，我们可以在低维表示上训练分类器，自动过滤输入数据中的随机噪音。



案例：特征脸

在人脸识别领域，PCA的应用尤为突出。通过对人脸图像数据集进行PCA分析，我们可以得到所谓的"特征脸"--这些是人脸图像数据的主成分。

使用Scikit-Learn中的LFW（Labeled Faces in the Wild）数据集，我们可以通过RandomizedPCA快速计算出高维人脸数据的前150个主成分。这些特征脸展示了人脸图像中的主要变化模式：前面几个特征脸与照向脸的光线角度有关，而后面的主向量则挑选出了特定的特征，如眼睛、鼻子和嘴唇。

这150个成分包含了约90%的方差，使我们能够有效地重构原始人脸图像。这说明我们的分类算法只需要在150维的数据上训练，而不需要在原始的近3000维数据上训练，大大提高了计算效率。



主成分分析的应用与局限

主成分分析因其广泛的用途和强大的可解释性，可以有效应用于大量场景和学科中。对于任意高维数据集，PCA是一个很好的起点：它可以帮助我们可视化点间关系，理解数据中的主要方差，以及评估数据的固有维度。

然而，PCA也有其局限性。它的主要弱点是容易受到数据集异常点的影响。为了解决这个问题，许多改进版本的PCA被开发出来，如RandomizedPCA和SparsePCA。前者使用非确定方法快速近似计算高维数据的主成分，后者引入正则项来保证成分的稀疏性。

尽管如此，PCA仍然是数据科学工具箱中不可或缺的工具，为我们提供了理解 and 处理高维数据的有效途径。

