

【机器学习】Bagging 算法



leedq

关注

32 人赞同了该文章 ›

Bagging 算法（英语：Bootstrap aggregating，引导聚集算法），又称装袋算法，是机器学习领域的一种团体学习算法。最初由 Leo Breiman 于 1996 年提出。Bagging 算法可与其他分类、回归算法结合，提高其准确率、稳定性的同时，通过降低结果的方差，避免过拟合的发生。

简介

Bagging [Breiman, 1996a] 是并行式集成学习方法最著名的代表。从名字即可看出，它直接基于[自助采样法](#)⁺(bootstrap sampling)。给定包含 m 个样本的数据集，我们先随机取出一个样本放入采样集中，再把该样本放回初始数据集，使得下次采样时该样本仍有可能被选中，这样，经过 m 次随机采样操作，我们得到含 m 个样本的采样集，初始训练集中有的样本在采样集里多次出现，有的则从未出现，初始训练集中约有 63.2% 的样本出现在来样集中。

照这样，我们可采样出 T 个含 m 个训练样本的采样集，然后基于每个采样集训练出一个基学习器，再将这些基学习器进行结合。这就是 Bagging 的基本流程。在对预测输出进行结合时，Bagging 通常对分类任务使用简单投票法，对回归任务使用简单平均法。若分类预测时出现两个类收到同样票数的情形，则最简单的做法是随机选择一个，也可进一步考察学习器投票的置信度来确定最终胜者。

Bagging 是通过结合几个模型降低[泛化误差](#)⁺的技术。主要想法是分别训练几个不同的模型，然后让所有模型表决测试样例的输出。这是机器学习中常规策略的一个例子，被称为[模型平均](#)⁺（model averaging）。采用这种策略的技术被称为集成方法。模型平均（model averaging）奏效的原因是不同的模型通常不会在测试集上产生完全相同的误差。模型平均是一个减少泛化误差的非常强大可靠的方法。


基本思想

1. 给定一个弱学习算法, 和一个训练集;
2. 单个弱学习算法准确率不高;
3. 将该学习算法使用多次, 得出预测函数序列, 进行投票;
4. 最后结果准确率将得到提高.



知乎

- 1. 对于给定的训练样本 S,每轮从训练样本 S 中采用有放回抽样(Booststraping)的方式抽取 M 个训练样本,共进行 n 轮,得到了 n 个样本集合,需要注意的是这里的 n 个训练集之间是相互独立的。
- 2. 在获取了样本集合之后,每次使用一个样本集合得到一个预测模型,对于 n 个样本集合来说,我们总共可以得到 n 个预测模型。
- 3. 如果我们需要解决的是分类问题,那么我们可以对前面得到的 n 个模型采用投票的方式得到分类的结果,对于回归问题来说,我们可以采用计算模型均值的方法来作为最终预测的结果。



特点在于随机采样,那么什么是随机采样(自组采样)呢?
随机采样 (bootstrap sample) 从 n 个数据点中有放回地重复随机抽取一个样本(即同一个样本可被多次抽取),共抽取 n 次。创建一个与原数据大小相同得数据集,但有些数据点会缺失(大约 1/3),有些会重复。
举例说明:
原数据集: ['a' , 'b' , 'c' , 'd']
随机采样 1: ['c' , 'd' , 'c' , 'a']
随机采样 2: ['d' , 'd' , 'a' , 'b']
...
对于缺失得数据点我们常常称之为**袋外数据***(Out Of Bag, 简称 OOB)。这些数据没有参与训练集模型的拟合,因此可以用来检测模型的泛化能力。

bagging 的集合策略也比较简单,对于分类问题,通常使用简单投票法,得到最多票数的类别或者类别之一为最终的模型输出。对于回归问题,通常使用简单平均法,对 T 个弱学习器得到的回归结果进行算术平均得到最终的模型输出。

发布于 2021-03-08 11:19

bagging 机器学习 集成学习

▲ 赞同 32 ▼ ● 添加评论 ↗ 分享 ❤ 喜欢 ★ 收藏 📄 申请转载 ...

知乎



理性发言，友善互动




还没有评论，发表第一个评论吧

推荐阅读



如何使用 Kafka 在生产环境构建大规模机器学习

AI 前线



利用深度学习建立流失模型

王向君

机器学习算法线上部署方法

我们经常会碰到一个问题：用了复杂的 GBDT 或者 xgboost 大大提升了模型效果，可是在上线的时候又犯难了，工程师说这个模型太复杂了，我没法上线，满足不了工程的要求，你帮我转换成 LR 吧，直接...

携程技术

发表于携程技术

【智能优化算法·爱钻研】-3 十分钟快速 get 蚁群算法（附代...

本文发布于公众号【数据魔术师】同名文章，欢迎给我们留言或者私信一起交流 秦虎教授的联系方式为微信号：43340630，更多新文章请关注微信公众号：数据魔术师之前分享了 TSP 的动态规划解法，...

tigerqin1980