

第3章 贝叶斯分类器

主讲 胡晓



目录

- 3.1 基本概念
 - 3.2 决策准则
 - 3.3 高斯混合模型
 - 3.4 未知概率密度函数估计
 - 3.5 朴素贝叶斯
 - 3.6 拉普拉斯平滑
- 

3.1 基本概念

➤ 概率

➤ 先验概率




➤ 把事先掌握的各类样本出现的概率称为先验概率

➤ $P(y = c) = \frac{N_c}{N}$

➤ 概率密度函数



➤ 连续随机样本的分布规律

➤ 正态分布、均匀分布、瑞利分布和泊松分布等



3.1 基本概念

- 概率
- 先验概率
- 概率密度函数, 先验概率密度函数
 - 连续样本 x 的pdf用 $p(x)$ 表示;
 - 对离散随机样本 x 用概率 $P(x)$ 表示
- 类条件概率密度函数
 - 描述某一类 $\mathcal{D}_c$ 随机样本的分布规律
 - $p(x|y = c)$




3.1 基本概念

- 概率, $P(\mathbf{x})$
- 先验概率, $P(y = c)$
- 概率密度函数, $p(\mathbf{x})$
- 类条件概率密度函数, $p(\mathbf{x}|y = c)$
- 后验概率 $P(y = c|\mathbf{x})$

根据贝叶斯准则和全概率公式

$$\begin{cases} P(y = c|\mathbf{x}) = \frac{p(\mathbf{x}|y = c)P(y = c)}{P(\mathbf{x})}, \\ P(\mathbf{x}) = \sum_{c=1}^C P(\mathbf{x}|y = c)P(y = c), \end{cases} \quad c = 1, 2, \dots, C$$



3.2 贝叶斯决策准则

误判风险因子, $r_{i,j}$, 也称为误判惩罚因子

$$r_{i,j} = \begin{cases} 0, & \text{如果 } i = j \\ r_{i,j}, & \text{如果 } i \neq j \end{cases}$$

第*i*类的期望损失为


$$\ell(\mathbf{x}|y=i) = \sum_{j=1}^c r_{i,j} P(y=j|\mathbf{x})$$

设在贝叶斯模型参数 $\boldsymbol{\theta}$ 下, 所有类别的期望损失之和构成总体期望损失,

$$\mathcal{L}(\boldsymbol{\theta}) = \sum_{i=1}^c \ell(\mathbf{x}|y=i) P(y=i)$$

最优分类器是训练一个使总体期望损失 $\mathcal{L}$ 最小的准则 $f(\mathbf{x}, \boldsymbol{\theta}): \mathcal{D} \mapsto \mathcal{Y}$, 即

$$\boldsymbol{\theta}^* = \arg \min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta})$$



3.2 贝叶斯决策准则

设在贝叶斯模型参数 θ 下，所有类别的期望损失之和构成总体期望损失，


最优分类器是训练一个使总体期望损失 $\mathcal{L}$ 最小的准则 $f(\mathbf{x}, \theta): \mathcal{D} \mapsto \mathcal{Y}$ ，即

$r_{i,j} = 1, \forall i \neq j$ 条件下贝叶斯决策准则：贝叶斯分类器将观测数据 $\mathbf{x}$ 决策为具有最大后验概率的类，

$$\mathcal{L}(\theta) = \sum_{i=1}^C \ell(\mathbf{x}|y=i)P(y=i)$$

$$\theta^* = \arg \min_{\theta} \mathcal{L}(\theta)$$

$$f(\mathbf{x}, \theta) = \arg \max_{c \in \mathcal{Y}} P(y=c|\mathbf{x})$$



3.3 高斯混合模型


由 K 个简单分布凸性组合成复杂概率模型，称为混合模型(Mixture Model)

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \cdot p(\mathbf{x}|\boldsymbol{\theta}_k)$$

高斯混合模型，其凸性组合形式为

$$p_{GMM}(\mathbf{x}) = \sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \Sigma_k)$$

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \Sigma_k) = \frac{1}{\sqrt{(2\pi)^d \Sigma_k}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma_k^{-1}(\mathbf{x} - \boldsymbol{\mu}_k)\right)$$



3.4 未知概率密度函数估计

3.4.1 极大似然估计(Maximum Likelihood Estimation, *MLE*)

一个 $\boldsymbol{\vartheta}$ 关于 $\boldsymbol{x}$ 的似然函数 $p(\boldsymbol{x}|\boldsymbol{\vartheta}) = p(\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_N|\boldsymbol{\vartheta}) = \prod_{n=1}^N p(\boldsymbol{x}_n|\boldsymbol{\vartheta})$

*MLE*的目标：从所有可能的 $\boldsymbol{\vartheta}$ 取值中选择使似然函数 $p(\boldsymbol{x}|\boldsymbol{\vartheta})$ 最大的参数 $\boldsymbol{\vartheta}^*$ ，即在参数 $\boldsymbol{\vartheta}^*$ 条件下样本集 $\boldsymbol{x}$ 出现的“可能性”最大，

$$\boldsymbol{\vartheta}^* = \arg \max_{\boldsymbol{\vartheta}} \prod_{n=1}^N p(\boldsymbol{x}_n|\boldsymbol{\vartheta})$$

对数似然函数 $L(\boldsymbol{\vartheta}) = \log(p(\boldsymbol{x}|\boldsymbol{\vartheta})) = \log \prod_{n=1}^N p(\boldsymbol{x}_n|\boldsymbol{\vartheta}) = \sum_{n=1}^N \log(p(\boldsymbol{x}_n|\boldsymbol{\vartheta}))$

最大化自然函数转化为最小化代价函数 $\tilde{\boldsymbol{\vartheta}}_{MLE} = \tilde{\boldsymbol{\vartheta}}_{NLL} = \arg \min_{\boldsymbol{\vartheta}} \left[- \sum_{n=1}^N \log(p(\boldsymbol{x}_n|\boldsymbol{\vartheta})) \right]$

3.4未知概率密度函数估计

3.4.2 极大后验概率估计(Maximum a Posteriori Estimation, *MAP*)

极大后验概率估计是把参数 $\boldsymbol{\vartheta}$ 看作随机向量，并服从某种分布规律， $p(\boldsymbol{\vartheta})$ 。然后，通过观测样本集 $\mathcal{X} = \{x_n\}_{n=1}^N$ 获得估计值 $\tilde{\boldsymbol{\vartheta}}$ 。

*MAP*的目标：从 $\boldsymbol{\vartheta}$ 所有可能的取值中选择使后验概率 $p(\boldsymbol{\vartheta}|\mathcal{X})$ 最大的参数 $\tilde{\boldsymbol{\vartheta}}$ ，即

$$\tilde{\boldsymbol{\vartheta}} = \arg \max_{\boldsymbol{\vartheta}} p(\boldsymbol{\vartheta}|\mathcal{X}) = \arg \max_{\boldsymbol{\vartheta}} \left(\frac{p(\boldsymbol{\vartheta})p(\mathcal{X}|\boldsymbol{\vartheta})}{p(\mathcal{X})} \right)$$

3.4未知概率密度函数估计

3.4.3 期望极大算法(Expectation Maximum Algorithm, EM)

期望极大算法算法可用于含有隐变量的概率模型的 MLE 或 MAP ，是一种迭代算法。

每次迭代有两步：

求期望(Expectation)的 E 步；

求极大(Maximization)的 M 步。

3.5 朴素贝叶斯

当观测样本 $\mathbf{x}_n$ 通常是由多个属性值, $x_{i,n}, i = 1, 2, \dots, d$, 构成的特征向量时, 贝叶斯分类准则中使用的类条件概率 $p(\mathbf{x}_n|y = c)$ 是所有属性值的联合概率,

$$p(\mathbf{x}_n|y = c) = p(x_{1,n}, x_{2,n}, \dots, x_{d,n}|y = c)$$

朴素贝叶斯(Naïve Bayes)采用属性条件独立性假设减少需估计的参数数量:

给定类条件下, 属性值 $x_{1,n}, x_{2,n}, \dots, x_{d,n}$ 是相互独立的随机变量。

基于独立性假设, 给定类条件下 d 个属性的联合概率因子分解(Factorization)成各属性的类条件概率相乘,

$$p(x_{1,n}, x_{2,n}, \dots, x_{d,n}|y = c) = \prod_{i=1}^d p(x_{i,n}|y = c), \quad x_{i,n} \in \mathcal{X}_i$$

3.6 拉普拉斯平滑

- 解决零概率的问题，法国数学家拉普拉斯最早提出用加1平滑估计没有出现过的现象的概率，即拉普拉斯平滑(Laplace smoothing)：对每个属性值对应计数样本数量计算加1。
- 拉普拉斯平滑是贝叶斯分类的一种常用方法。贝叶斯估计公式改写为，

$$\begin{cases} P_{\lambda}(x_{,i} = a_{i,j} | y = c) = \frac{\lambda + \sum_{n=1}^N \mathbb{I}(x_{,i} = a_{i,j}, y = c)}{\lambda S_i + \sum_{n=1}^N \mathbb{I}(y = c)} \\ P_{\lambda}(y = c) = \frac{\lambda + \sum_{n=1}^N \mathbb{I}(y = c)}{\lambda C + N} \end{cases}$$



谢谢！

