

第四章 贝叶斯

贝叶斯系列算法是基于贝叶斯定理和概率统计原理的一类算法。它们通过对特征之间的条件概率进行建模，从而进行分类、回归、聚类等任务。贝叶斯模型作为一种重要的机器学习模型已在数据挖掘、计算机视觉、自然语言理解、经济统计与预测等领域得到广泛应用。贝叶斯系列算法在处理小样本问题、噪声数据以及不确定性建模方面具有优势，并且能够有效利用先验知识进行模型推理与预测。

4.1 贝叶斯方法概述

贝叶斯方法提供了一种基于主观概率的数理统计分析方法，使用概率分布表示和理解样本数据，根据样本的先验概率分布和训练样本的标记数据计算出相应的后验概率分布，以贝叶斯风险为优化目标实现对样本数据的分类或回归。

4.1.1 贝叶斯公式

用 $P(A)$ 和 $P(B)$ 分别表示事件A和B发生的概率，用 $P(A|B)$ 表示在B已发生的条件下A发生的概率，即事件A对事件B的条件概率，则根据条件概率的定义和性质有：

$$P(B|A) = \frac{P(B)P(A|B)}{P(A)}$$

假设事件A表示机器学习任务中样本的取值状态为 X ，事件B表示机器学习模型参数 θ 的取值为 θ_i ，则上述公式转化为：

$$P(\theta_i|X) = \frac{P(\theta_i)P(X|\theta_i)}{P(X)}$$

4.1.1 贝叶斯公式

假设模型参数的各取值状态互不相容，则可根据全概率公式得到概率 $P(X)$ 。

$$P(X) = \sum_k P(X|\theta_k) P(\theta_k)$$

因此可求得

$$P(\theta_i|X) = \frac{P(\theta_i)P(X|\theta_i)}{\sum_k P(X|\theta_k) P(\theta_k)}$$

4.1.1 贝叶斯公式

通常需要通过主观经验确定 $P(\theta_i)$ 的取值，也就是说 $P(\theta_i)$ 是一种先验概率，令：

$$C(X|\theta_i) = \frac{P(X|\theta_i)}{\sum_k P(X|\theta_k) P(\theta_k)}$$

则有 $P(\theta_i|X) = P(\theta_i)C(X|\theta_i)$

即后验概率=先验概率 $\times$ 样本信息。

因此贝叶斯公式的本质就是根据样本取值状态 X 修正先验概率 $P(\theta_i)$ 以得到后验概率 $P(\theta_i|X)$ 。

4.1.2 贝叶斯决策理论

贝叶斯决策具体步骤：

- 1) 定义决策空间：确定可供选择的决策及其可能的结果。
- 2) 确定先验概率：对每个可能的结果（即条件）估计先验概率。
先验概率可以基于经验或专家知识进行估计。
- 3) 观测到证据：收集到与决策相关的证据或观测数据。
- 4) 计算后验概率：根据贝叶斯定理，将先验概率和观测到的证据相结合，计算各个条件下的后验概率。
- 5) 选择最优决策：根据后验概率，选择具有最大后验概率的决策，作为最优的决策。

4.1.3 极大似然估计

极大似然估计具体步骤：

- 1) 确定概率分布模型：假设观测数据符合某个特定的概率分布模型，如正态分布、伯努利分布等。
- 2) 建立似然函数：将观测数据看作是参数的函数，构建似然函数。似然函数表示给定参数值下观测数据出现的概率。
- 3) 最大化似然函数：找到使似然函数取得最大值的参数值，即寻找最大似然估计。通常使用优化算法，如梯度下降法或牛顿法，求解似然函数的最大值点。
- 4) 得出估计值：最大似然估计得到的参数值即为所要求的估计值。

4.1.3 极大似然估计

具体而言先验概率 $p(Y = c_k)$ 的极大似然估计是：

$$p(Y = c_k) = \frac{\sum_{i=1}^n I(y_i = c_k)}{N}, k=1, 2, \dots, K$$

设第 j 个特征 $x^{(j)}$ 可能取值的集合为 $\{a_{j1}, a_{j2}, \dots, a_{js_j}\}$, 条件概率 $P(X^{(j)} = a_{jl} | Y = c_k)$ 的极大似然估计是：

$$P(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)}$$

4.2 朴素贝叶斯算法

朴素贝叶斯算法的核心思想是根据给定的特征向量，通过计算后验概率来确定该样本属于不同类别的概率，然后选择具有最大后验概率的类别作为分类结果。

4.2 朴素贝叶斯算法

设输入空间 $\chi \subseteq R^n$ 为 n 维向量的集合，输出空间为类标记集合 $\mathcal{Y}=\{c_1, c_2, \dots, c_k\}$ ， X 是定义在输入空间 χ 上的随机变量， Y 是定义在输出空间 $\mathcal{Y}$ 上的随机变量。 $P(X, Y)$ 是 X 和 Y 的联合概率分布。训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ 由 $P(X, Y)$ 独立同分布产生。

数据集的先验概率分布为

$$P(Y = c_k), \quad k = 1, 2, \dots, K$$

条件概率分布为

$$P(X = x|Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_k), \quad k = 1, 2, \dots, K$$

4.2 朴素贝叶斯算法

朴素贝叶斯法对条件概率分布作了条件独立性的假设

$$\begin{aligned} P(X = x|Y = c_k) &= P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_k) \\ &= \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k) \end{aligned}$$

朴素贝叶斯法分类时，对给定的输入 x ，通过学习到的模型计算后验概率分布 $P(Y = c_k|X = x)$ ，将后验概率最大类作为 x 的类输出。

4.2 朴素贝叶斯算法

后验概率计算根据贝叶斯定理可表示为

$$P(Y = c_k | X = x) = \frac{P(X = x | Y = c_k) P(Y = c_k)}{\sum_k P(X = x | Y = c_k) P(Y = c_k)}$$

$$P(Y = c_k | X = x) = \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}, \quad k = 1, 2, \dots, K$$

$$y = f(x) = \operatorname{argmax}_{c_k} \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}$$

因分母对所有 c_k 都是相同的

$$y = \operatorname{argmax}_{c_k} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)$$

4.2.1 高斯朴素贝叶斯

高斯朴素贝叶斯算法是一种基于贝叶斯定理和特征独立性假设的分类算法，适用于处理连续特征的分类问题。

高斯朴素贝叶斯算法假设每个特征 x_i 在给定类别 k 下服从高斯分布：

$$p(x_i|\theta_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right)$$

4.2.1 高斯朴素贝叶斯

对于一个新的测试样本，算法先计算该样本在每个类别下的后验概率。使用高斯分布的概率密度函数，算法计算每个特征值在给定类别下的对数似然。然后，将先验概率和对数似然相加得到后验概率。最后，选择具有最大后验概率的类别作为预测结果。

高斯朴素贝叶斯算法的优势在于它对于大规模数据集具有较高的训练和预测效率，并且对于缺失数据的处理比较鲁棒。然而，它的一个主要限制是它假设特征之间是独立的，这在某些实际问题中可能不符合实际情况，因此其结果可能受到特征相关性的影响。

4.2.2 多项式朴素贝叶斯

多项式朴素贝叶斯假设每个特征的出现次数是由多项分布生成的，即特征的计数符合多项分布。根据先验概率和条件概率计算每个类别的后验概率，并选择具有最大后验概率的类别作为预测结果。

对于每个测试样本，算法会计算特征的计数，并使用条件概率计算后验概率。

4.2.3 伯努利朴素贝叶斯

伯努利朴素贝叶斯算法的主要思想是将文档表示为二进制特征向量，其中每个特征表示单词或特定的文本属性是否出现。因此每个特征的取值是布尔型的，即true和false，或者1和0。它基于一个关键假设，即每个特征在给定类别下是条件独立的。

在训练过程中，遍历类别和特征，并根据特征是否存在来根据贝叶斯公式计算后验概率。最后选择具有最大后验概率的类别作为预测结果。

4.3 半朴素贝叶斯算法

半朴素贝叶斯算法的核心思想是，适当考虑一部分属性间的相互依赖信息。假设给定某个类别的条件下，特征之间的相关性可被一些选定的特征表示。

相比于传统的朴素贝叶斯算法，半朴素贝叶斯算法考虑了特征之间的相关性，可以更准确地捕捉数据中的复杂关系。并且该算法允许根据具体问题选择不同的核心特征和配对特征组合，可以适应不同类型的数据集和任务需求

4.3 半朴素贝叶斯算法

独依赖估计（One-Dependent Estimator, ODE）是半朴素贝叶斯分类器最常用的一种策略。独依赖是假设每个属性在类别之外最多依赖一个其他属性，即：

$$P(x|c_i) = \prod_{j=1}^d P(x_j|c_i, pa_j)$$

若父属性 pa_j 为已知，可以使用下面的公式估计 $P(x_j|c_i, pa_j)$ ：

$$P(x_j|c_i, pa_j) = \frac{P(x_j, c_i, pa_j)}{P(c_i, pa_j)}$$

4.3 半朴素贝叶斯算法

相比于传统的朴素贝叶斯算法，半朴素贝叶斯算法考虑了特征之间的相关性。这使得模型可以更准确地捕捉数据中的复杂关系。半朴素贝叶斯算法允许根据具体问题选择不同的核心特征和配对特征组合。这种灵活性使得算法可以适应不同类型的数据集和任务需求。此外，半朴素贝叶斯算法在处理高维数据时表现出较好的性能，因为它可以通过选择核心特征和相关特征来减少特征空间的维度。

但是，在半朴素贝叶斯算法中，仍然假设给定类别下的特征是相互独立的。然而，在实际问题中，特征之间通常存在一定的依赖关系。为了解决这个问题，可以引入更复杂的模型，如贝叶斯网络、树模型等，以捕捉特征之间的依赖性。


4.4 贝叶斯网络算法

贝叶斯网络（Bayesian Networks）也被称为信念网络（Belief Networks）或者因果网络（Causal Networks），是描述数据变量之间依赖关系的一种图形模式，是一种用来进行推理的模型。贝叶斯网络为人们提供了一种方便的框架结构来表示因果关系。

4.4.1 贝叶斯网结构


在贝叶斯网结构中，一条弧由一个属性A指向另外一个属性B说明属性A的取值可以对属性B的取值产生影响，由于是有向无环图，A、B间不会出现有向回路。在贝叶斯网当中，直接的原因结点（弧尾）A叫做其结果结点（弧头）B的双亲结点（parents），B叫做A的孩子结点（children）。如果从一个结点X有一条有向通路指向Y，则称结点X为结点Y的祖先（ancestor），同时称结点Y为结点X的后代（descendent）。

4.4.1 贝叶斯网结构




左图中共有四个结点和四条弧。高油高糖饮食X1是一个原因结点，它会导致糖尿病X2和高血脂X3。而我们知道糖尿病X2和高血脂X3都可能最终导致心脏病X4。


4.4.1 贝叶斯网结构



同父结构



V型结构



顺序结构

贝叶斯网络的一个重要性质是：当一个节点的父节点概率分布确定之后，该节点条件独立于其所有的非直接父节点。在“同父”结构中，给定父节点 x_1 的取值，则 x_3 与 x_4 条件独立。在“顺序”结构中，给定 x 的值，则 y 与 z 条件独立。V型结构亦称“冲撞”结构，给定子节点 x_4 的取值， x_1 和 x_2 必不独立；奇妙的是，若 x_4 的取值完全未知，则V型结构下 x_1 和 x_2 却是互相独立的

4.4.2 贝叶斯网学习算法

贝叶斯网学习的首要任务就是根据训练数据集来找出结构最“恰当”的贝叶斯网。“评分搜索”是求解这一问题的常用办法。具体来说，我们先定义一个评分函数，以此来评估贝叶斯网与训练数据的契合程度，然后基于这个评分函数来寻找结构最优的贝叶斯网。

4.4.2 贝叶斯网学习算法

给定训练集 $D = \{x_1, x_2, \dots, x_m\}$, 贝叶斯网 $B = \langle G, \theta \rangle$ 在 D 上的评分函数可写为

$$s(B|D) = f(\theta)|B| - LL(B|D)$$

贝叶斯网 B 的对数似然为:

$$LL(B|D) = \sum_{i=1}^m \log P_B(x_i)$$

寻找一个贝叶斯网 B 使评分函数 $s(B|D)$ 最小

若 $f(\theta) = 1$, 即每个参数用1字节描述, 则得到ACI评分函数

$$ACI(B|D) = |B| - LL(B|D)$$

4.4.2 贝叶斯网学习算法

若 $f(\theta) = \frac{1}{2} \log m$ ，即每个参数用 $\frac{1}{2} \log m$ 字节描述，则得到BCI评分函数

$$BCI(B|D) = \frac{1}{2} \log m |B| - LL(B|D)$$

若 $f(\theta) = 0$ ，即不计算对网络进行编码的长度，则评分函数退化为负对数似然，相应的，学习任务退化为极大似然估计。

同时若贝叶斯网 $B = \langle G, \theta \rangle$ 的网络结构 G 固定，则评分函数 $s(B|D)$ 的第一项为常数。此时，最小化 $s(B|D)$ 等价于对参数 θ 的极大似然估计。

4.4.3 贝叶斯网推断

在现实应用中，贝叶斯网的近似推断常使用吉布斯采样来完成，这是一种随机采样方法。

令 $Q = \{Q_1, Q_2, \dots, Q_n\}$ 表示待查询变量， $E = \{E_1, E_2, \dots, E_k\}$ 为证据变量，已知其取值为 $e = \{e_1, e_2, \dots, e_k\}$ 。目标是计算后验概率 $P(Q = q|E = e)$ 。吉布斯采样算法先随机产生一个与证据 $E = e$ 一致的样本 q^0 作为初始点，然后每步从当前样本出发产生下一个样本。

假定经过 T 次采样得到的与 q 一致的样本共有 n_q 个，则可近似估算出后验概率

$$P(Q = q|E = e) \simeq \frac{n_q}{T}$$

4.4.3 贝叶斯网推断

实质上，吉布斯采样是在贝叶斯网所有变量的联合状态空间与证据 $E = e$ 一致的子空间中进行“随机漫步”。每一步仅依赖于前一步的状态，是一个“马尔可夫链”。

由于马尔可夫链通常需很长时间才能趋于平稳分布，因此吉布斯采样算法的收敛速度较慢。此外，若贝叶斯网中存在极端概率“0”或“1”，则不能保证马尔可夫链存在平稳分布，此时吉布斯采样会给出错误的估计结果。

4.5 EM算法

未观测变量的学名是“隐变量”。令 X 表示很已观测变量集， Z 表示隐变量集， θ 表示模型参数。若欲对 θ 做极大似然估计，则应最大化对数似然：

$$LL(\theta|X, Z) = \ln P(X, Z, \theta)$$

由于 Z 是隐变量，上式无法直接求解。此时可通过对 Z 计算期望，来最大化已观测数据的对数“边际似然”：

$$LL(\theta|X, Z) = \ln P(X|\theta) = \ln \sum_Z P(X, Z, \theta)$$

4.5 EM算法

EM算法的每次迭代由两步组成：E步，求期望（expectation）；M步，求极大（maximization），所以这一算法称为期望极大算法（expectation maximization algorithm），简称EM算法。

EM算法使用两个步骤交替计算：第一步是期望(E)步，利用当前估计的参数值来计算对数似然的期望值；第二步是最大化(M)步，寻找能使E步产生的似然期望最大化的参数值。然后，新得到的参数值重新被用于E步，直到收敛到局部最优解。

4.5 EM算法

例 三硬币模型

假设有A、B、C三枚硬币，其出现正面的概率分别为 π ， p 和 q 。使用三枚硬币进行如下试验：先抛掷硬币A，根据其结果来选择硬币B或者C，假设正面选B，反面选C，然后记录硬币结果，正面记为1，反面记为0，独立重复5次试验，每次试验重复抛掷B或者C10次。问如何估计三枚硬币分别出现正面的概率。

4.5 EM算法

E步：初始化B和C出现正面的概率为 $\hat{\theta}_B^{(0)} = 0.6$ 和 $\hat{\theta}_C^{(0)} = 0.5$ ，估计每次试验中选择B还是C的概率，例如选择B的概率为：

$$P(z = B | y_1, \theta) = \frac{P(z = B, y_1 | \theta)}{P(z = B, y_1 | \theta) + P(z = C, y_1 | \theta)} = \frac{(0.6)^5 \times (0.4)^5}{(0.6)^5 \times (0.4)^5 + (0.5)^{10}} = 0.45$$

计算出每次试验选择B和C的概率，然后根据试验数据进行加权求和。

M步：更新模型参数的新估计值。根据函数求导来确定参数值：

$$\begin{aligned} Q(\theta, \theta^i) &= \sum_{j=1}^5 \sum_z P(z | y_j, \theta^i) \log P(z | y_j, \theta) \\ &= \sum_{j=1}^5 \mu_j \log(\theta_B^{y_j} (1 - \theta_B)^{10 - y_j}) + (1 - \mu_j) \log(\theta_B^{y_j} (1 - \theta_B)^{10 - y_j}) \end{aligned}$$

对上式求导并令其值为0可得第一次迭代后的参数值，然后重复进行第二轮、第三轮，直至模型收敛。

4.6 本章小结

本章主要介绍了贝叶斯，讲解了其理论、朴素贝叶斯算法、半朴素贝叶斯算法、贝叶斯算法、EM算法。

朴素贝叶斯法是基于贝叶斯定理与特征条件独立假设的分类方法。朴素贝叶斯的“朴素”体现在，假设各属性之间没有相互依赖。贝叶斯网络也被称为信念网络或者因果网络，是描述数据变量之间依赖关系的一种图形模式，是一种用来进行推理的模型。EM算法是一种迭代算法，用于含有隐变量的概率模型参数的极大似然估计，或极大后验概率估计。